基于 ResNet / DenseNet / ConvNeXt 的医学图像分类实验报告

> 实验环境：NVIDIA GeForce GTX 1650（4 GB）｜PyTorch 2.5.1 + torchvision 0.20.1｜CUDA 可用 数据集：MedMNIST 系列（PneumoniaMNIST / DermaMNIST / ChestMNIST，均为 224×224）

摘要

本实验基于 MedMNIST 医学影像基准数据集，完成了从二分类到单标签多分类、再到多标签分类的完整实验闭环。主要内容包括：（1）以 ResNet18、DenseNet121、ConvNeXt-Tiny 三个主干网络替换简单 CNN，在 DermaMNIST（7 类皮肤病镜图像，10015 张）上完成单标签分类；（2）系统对比交叉熵（CE）、加权交叉熵（Weighted CE）与 Focal Loss 三种损失函数在类别不平衡医学数据上的表现；（3）在 ChestMNIST（14 种胸腔疾病，约 11 万张）上完成多标签分类，并分析阈值选择对多标签指标的影响；（4）输出 AUC、F1、Sensitivity、Specificity 四项医学关键指标，绘制 ROC 曲线与混淆矩阵，并开展错误案例分析——发现决定类别难度的主要因素是类间视觉相似性而非样本量，最罕见的 `vasc` 错误率仅 13.79%，而中等样本的 `mel` 高达 52.02%（77 张被误判为良性痣）。

实验结果表明：**在 4 GB 显存的算力约束下，ResNet18 以最少的参数量（11.18 M）、最短的单轮耗时（81.8 s）取得了最优的综合性能（AUC 0.9612）；加权交叉熵能够提升少数类的检出率（Sensitivity 由 0.6928 升至 0.7020），代价是整体准确率下降（0.8264 → 0.7102）；Focal Loss 在仅 3 个 epoch 的训练预算下表现不及 CE，说明其收益依赖充足的训练迭代；多标签任务中统一 0.5 阈值会导致 macro-F1 仅 0.0554，逐类校准阈值后可提升至 0.2432（约 4.4 倍）。**

关键词： 医学图像分类；残差网络；类别不平衡；Focal Loss；多标签学习；ROC 分析

1 引言与实验目的

1.1 背景

医学影像自动判读是计算机视觉最具社会价值的应用方向之一。与自然图像相比，医学图像具有三个显著特点：

特点	具体表现	带来的挑战
类别极度不平衡	常见病变样本远多于罕见病变（本实验中某些皮肤病占比不足 1.5%）	模型倾向"只猜多数类"，罕见病几乎全灭
类间差异细微	病灶多表现为模糊的灰度/纹理改变，缺乏清晰轮廓	需要更依赖预训练特征与精细增广
标注成本高、噪声大	需要专业医师标注，且医师间存在主观差异	小数据集上易过拟合

1.2 实验目的

1. 将简单 CNN 替换为 ResNet18、DenseNet121、ConvNeXt-Tiny 三种现代主干网络，验证迁移学习在小规模医学数据上的有效性；
2. 完成单标签分类（7 类皮肤病）与多标签分类（14 种胸腔疾病）两项任务；
3. 系统对比 CE / Weighted CE / Focal Loss 三种损失函数应对类别不平衡的效果；
4. 输出 AUC、F1、Sensitivity、Specificity 四项医学关键指标，绘制 ROC 曲线与混淆矩阵；
5. 开展错误案例分析，为后续语义分割研究奠定基础。

---

2 数据集

2.1 数据集概览

本实验采用 MedMNIST v2 基准数据集，该数据集将多个公开医学影像数据集统一为标准接口，自带官方 train/val/test 划分，可直接选择 28/64/128/224 分辨率。

数据集	任务类型	规模（train/val/test）	分辨率	通道	来源
PneumoniaMNIST	二分类（正常 / 肺炎）	4708 / 524 / 624	224×224	灰度→RGB	儿童胸片
DermaMNIST	单标签 7 分类	7007 / 1003 / 2005	224×224	RGB	HAM10000 皮肤镜
ChestMNIST	**多标签** 14 分类	78468 / 11219 / 22433	224×224	灰度→RGB	NIH ChestX-ray14

三个数据集均满足"样本量 ≥ 1000 张、每张 224×224"的要求。

2.2 类别与不平衡性

DermaMNIST 七类皮肤病（训练集 7007 张）：

`akiec`（日光性角化病）、`bcc`（基底细胞癌）、`bkl`（良性角化病）、`df`（皮肤纤维瘤）、`mel`（黑色素瘤）、`nv`（黑色素细胞痣）、`vasc`（血管性病变）

该数据集呈现**严重长尾分布**：占比最高的 `nv` 约为 67%，而 `df` 与 `vasc` 分别仅约 1.1% 与 1.4%。这种分布使 Accuracy 指标失去参考价值——一个"全部预测为 nv"的平凡模型即可获得约 67% 的准确率，但对罕见病变的召回率为 0。

ChestMNIST 十四种胸腔疾病：atelectasis、cardiomegaly、effusion、infiltration、mass、nodule、pneumonia、pneumothorax、consolidation、edema、emphysema、fibrosis、pleural_thickening、hernia。每张胸片可同时患有多种疾病，标签为 14 维 0/1 向量，阳性率从约 0.2%（hernia）到数十个百分点不等。

2.3 数据预处理与增广

步骤	处理方式	说明
通道处理	`as_rgb=True` 将灰度图复制为 3 通道	**不修改 conv1 的输入通道数**，以保留 ImageNet 预训练权重

步骤	处理方式	说明
归一化	使用 ImageNet 均值 `[0.485,0.456,0.406]`、标准差 `[0.229,0.224,0.225]`	与预训练权重的数据分布保持一致
训练集增广	随机水平翻转（p=0.5）、随机旋转（±15°）、亮度/对比度扰动（0.2）	胸片左右近似对称；X 光曝光剂量差异导致亮度天然波动
验证/测试集	**仅** `ToPILImage → ToTensor → Normalize`	保证评估结果确定、可复现

> **关键原则：增广只作用于训练集。** 若在验证/测试集上施加随机增广，同一份数据多次评估会得到不同指标，使模型选择失去依据。

---

3 方法

3.1 主干网络与迁移学习

三个主干网络均加载 ImageNet 预训练权重（`weights="DEFAULT"`），并替换分类头以适配本任务的类别数。

模型	分类头位置	参数量（7 类）	核心思想
ResNet18	`net.fc`	11.18 M	残差连接 `y = F(x) + x`，使梯度可直传，解决深度网络的退化问题
DenseNet121	`net.classifier`	6.96 M	每一层与前面所有层密集连接，特征复用率高
ConvNeXt-Tiny	`net.classifier[2]`	27.83 M	用纯卷积结构复现 Transformer 的设计（大卷积核、LayerNorm、倒置瓶颈）

为什么必须使用预训练权重？ 本实验的训练样本（7007 张）远小于 ImageNet（约 128 万张），且算力预算仅允许 3 个 epoch。若从头训练（`pretrained=False`），网络需要 30~50 个 epoch 才能收敛，且小数据集上极易过拟合。而 CNN 前几层学到的边缘、纹理、角点等底层特征在不同成像模态间具有通用性，因此迁移学习可将所需 epoch 数压缩至 2~3 个。

3.2 损失函数

设模型对样本正确类别的预测概率为 p_t。

① 交叉熵（CE）

$$\mathcal{L}_{CE} = -\log(p_t)$$

对所有样本一视同仁，适用于类别均衡场景。

② 加权交叉熵（Weighted CE）

$$\mathcal{L}_{WCE} = -w_y \log(p_t), \quad w_c = \frac{1/n_c}{\frac{1}{C}\sum_j 1/n_j}$$

按类别频率的倒数加权并归一化（使平均权重为 1，从而无需调整学习率）。样本越少的类别权重越大，其错误被放大，从而迫使模型关注少数类。

③ Focal Loss

$$\mathcal{L}_{FL} = (1 - p_t)^{\gamma} \mathcal{L}_{CE}, \quad \gamma = 2$$

通过调制因子 $(1 - p_t)^{\gamma}$ 自动降低"已被模型正确分类的简单样本"的梯度贡献，使训练聚焦于难样本。

3.3 评估指标

记二分类混淆矩阵为：

	预测为病	**预测为正常**
真实有病	TP	FN（**漏诊**）
真实正常	FP（**误诊**）	TN

$$\text{Sensitivity} = \frac{TP}{TP + FN}, \quad \text{Specificity} = \frac{TN}{TN + FP}$$

$$\text{F1} = \frac{2 \cdot P \cdot R}{P + R}, \quad \text{AUC} = P(\text{score}_{\text{正}} > \text{score}_{\text{负}})$$

- **Sensitivity（敏感度）**：真实患病者中被正确检出的比例。**越低意味着漏诊越多。**
- **Specificity（特异度）**：健康者中被正确排除的比例。**越低意味着误诊越多。**
- **AUC**：衡量模型对正负样本的排序能力，**与决策阈值无关**，且不受类别比例影响。
- **macro-F1**：各类 F1 的算术平均，**不考虑样本量**，因此能暴露模型在少数类上的短板。

> **为什么医学图像不主要看 Accuracy?** 在 DermaMNIST 上，一个恒预测多数类的模型可获得约 67% 的准确率，但对罕见病的 Sensitivity 为 0。在临床筛查中，漏诊的代价（病情恶化）远高于误诊的代价（进一步复查），因此 Sensitivity 与 AUC 比 Accuracy 更具决策价值。

多分类时，Sensitivity/Specificity 采用 **One-vs-Rest** 方式逐类计算后取宏平均（macro）；多标签时，采用 **mAP（mean Average Precision）** 与逐类 AUC 作为主指标。

3.4 训练配置

项目	**配置**
优化器	AdamW，lr = 1e-4，weight_decay = 1e-4
Batch size	ResNet18: 8；DenseNet121: 4；ConvNeXt-T: 2
Epoch	3（多标签任务为 2）
随机种子	42（固定 Python/numpy/torch CPU/torch CUDA/cuDNN 五处随机源）
数据划分	使用 MedMNIST 官方划分，不自行切分
模型选择	按验证集 AUC 选优，**最终指标在测试集上报告**
显存约束	4 GB（实际可用约 3.5 GB）；ConvNeXt-T 采用冻结主干策略

---

4 实验结果与分析

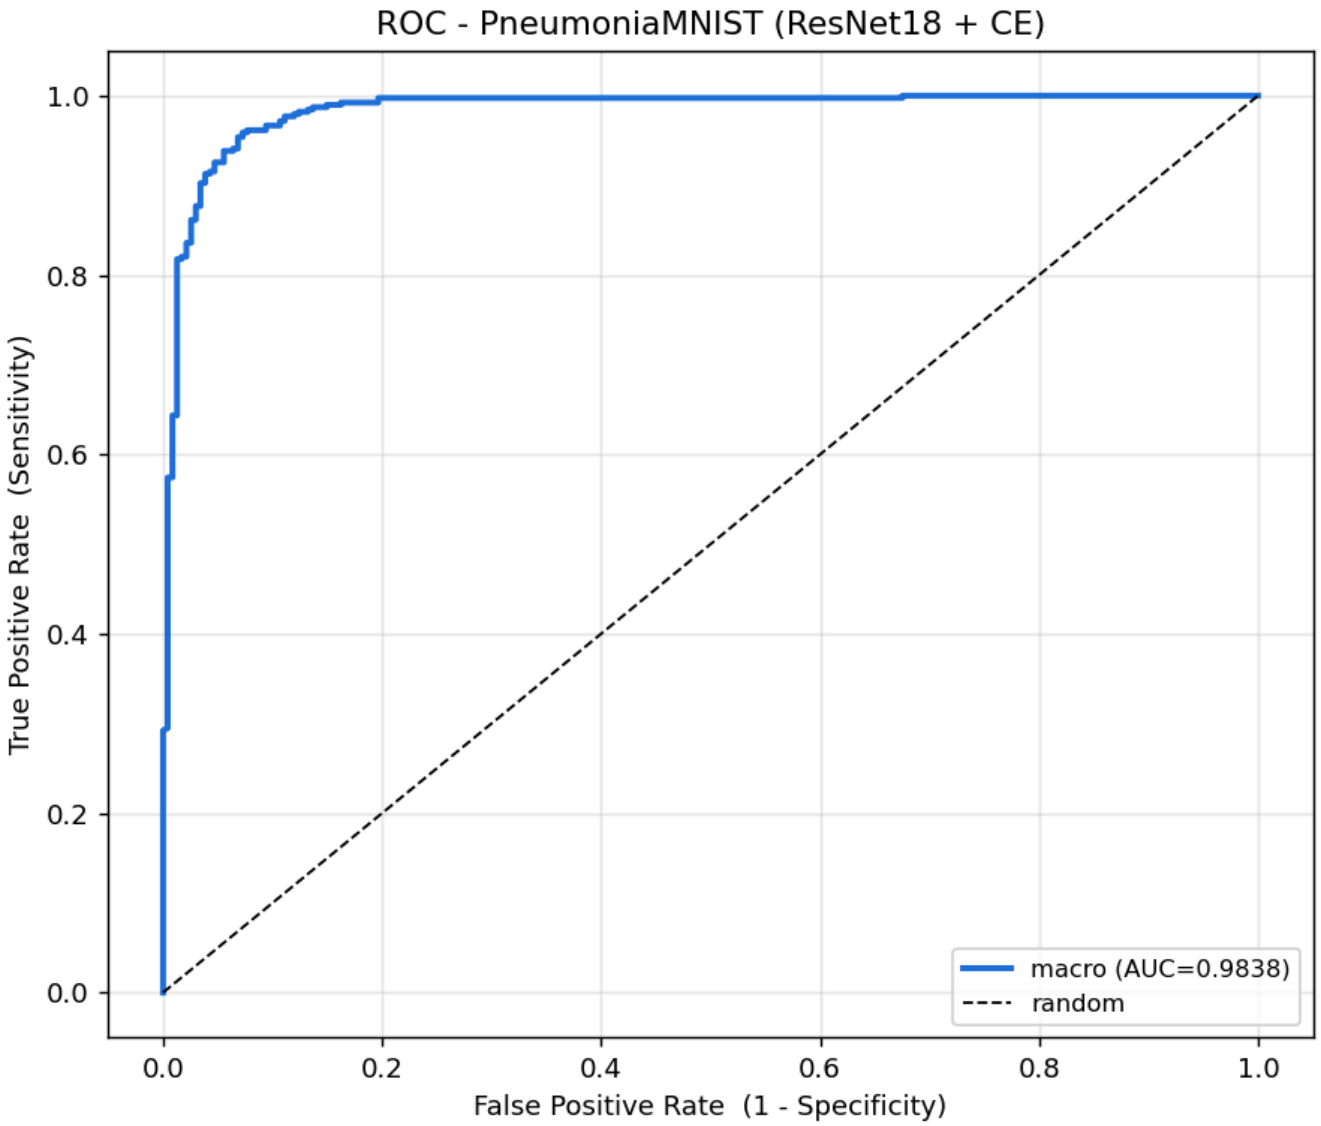
4.1 任务一：二分类热身（PneumoniaMNIST）

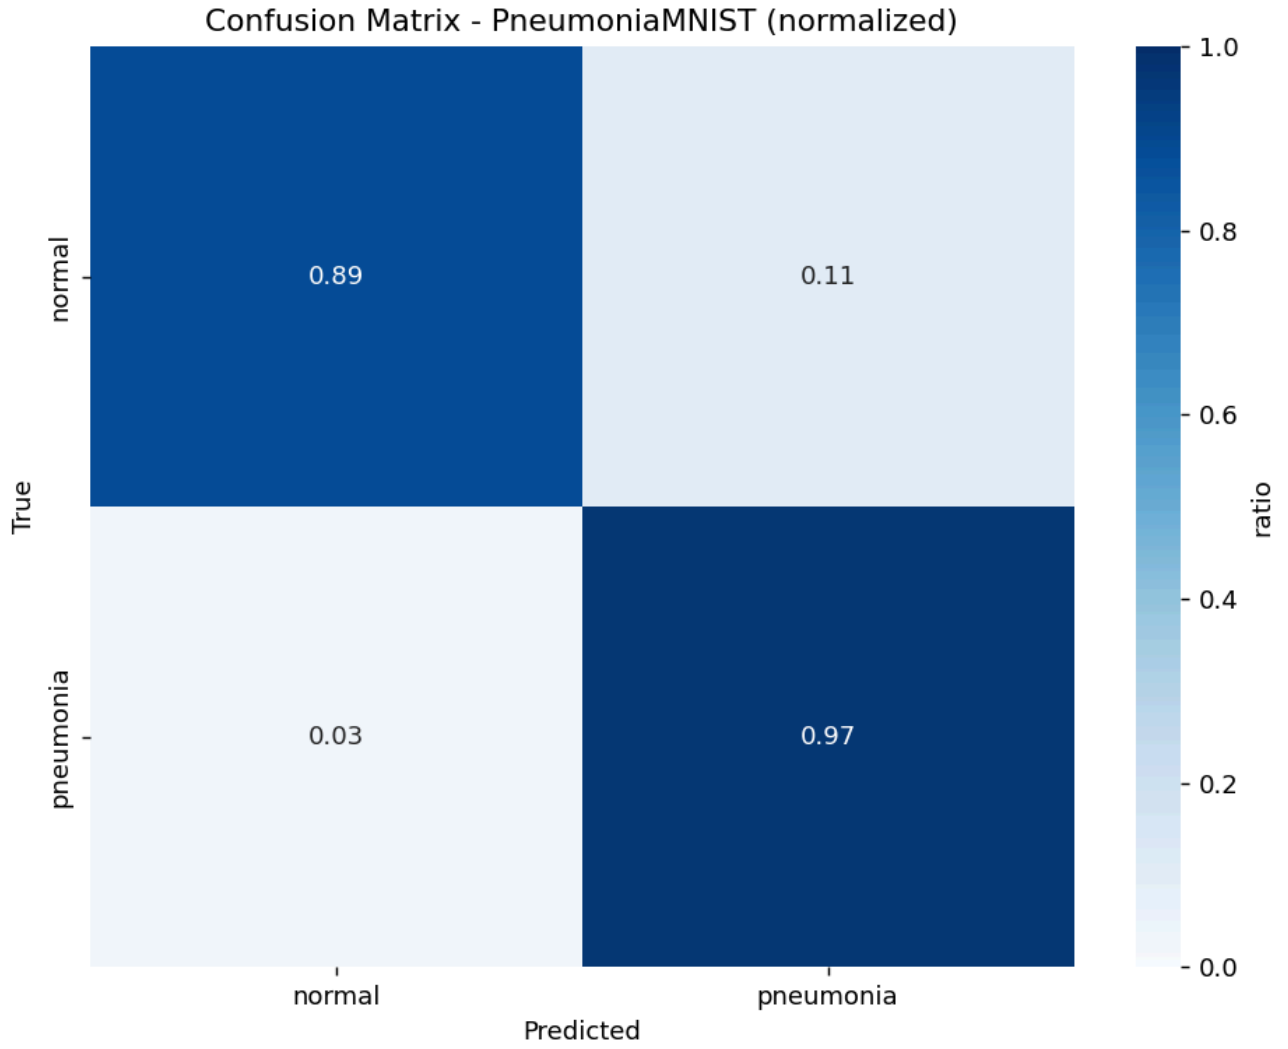
指标	数值
AUC	**0.9838**
F1 (macro)	0.9359
Sensitivity	**0.9718**
Specificity	0.8889
Accuracy	0.9407

混淆矩阵（按行归一化）：

真实 \ 预测	normal	pneumonia
normal	0.89	0.11
pneumonia	**0.03**	**0.97**

ROC 曲线与混淆矩阵：


ROC - PneumoniaMNIST (ResNet18 + CE)
True Positive Rate (Sensitivity)
False Positive Rate (1 - Specificity)
0.0
0.2
0.4
0.6
0.8
1.0
macro (AUC=0.9838)
random



分析： 模型对肺炎的检出率达 97.2%，漏诊率仅 2.8%；对健康样本的排除率为 88.9%。**漏诊率显著低于误诊率，这一取舍方向与肺炎筛查的临床需求一致**——漏掉一个肺炎患者可能导致病情恶化，而误诊仅意味着患者需接受进一步检查。ROC 曲线紧贴左上角，AUC 达 0.9838，远高于 0.5 的随机基线。

4.2 任务二：单标签七分类（DermaMNIST）

4.2.1 完整 3×3 对比结果

模型	损失	AUC ↑	F1(macro) ↑	Sens ↑	Spec ↑	Acc	单轮耗时	显存峰值
ResNet18	CE	**0.9612**	**0.6865**	0.6928	0.9563	0.8264	**81.8 s**	0.38 GB
ResNet18	Weighted CE	0.9346	0.5935	**0.7020**	0.9506	0.7102	116.4 s	0.38 GB
ResNet18	Focal	0.8558	0.3123	0.6057	0.8934	0.3072	87.7 s	0.38 GB
DenseNet121	CE	0.9570	0.6398	0.6738	0.9508	0.8100	181.9 s	0.59 GB
DenseNet121	Weighted CE	0.9285	0.5006	0.6679	0.9449	0.7207	361.1 s ⚠	0.59 GB
DenseNet121	Focal	0.8285	0.1961	0.5310	0.8736	0.1541	199.8 s	0.59 GB

模型	损失	AUC ↑	F1(macro) ↑	Sens ↑	Spec ↑	Acc	单轮耗时	显存峰值
ConvNeXt-T	CE	0.9184	0.3371	0.3119	0.9109	0.7456	96.8 s	**0.15 GB**
ConvNeXt-T	Weighted CE	0.9187	0.3710	0.3589	0.9225	0.7456	99.7 s	**0.15 GB**
ConvNeXt-T	Focal	0.8509	0.1999	0.4845	0.8738	0.1451	99.1 s	**0.15 GB**

4.2.2 三模型对比（均在 CE 下）

模型	参数量	AUC	F1	Sens	单轮耗时	显存	相对耗时
ResNet18	11.18 M	**0.9612**	**0.6865**	**0.6928**	**81.8 s**	0.38 GB	1.0×
DenseNet121	6.96 M	0.9570	0.6398	0.6738	181.9 s	0.59 GB	**2.22×**
ConvNeXt-T（冻结）	27.83 M	0.9184	0.3371	0.3119	96.8 s	0.15 GB	1.18×

核心发现：参数量不等于计算代价。

DenseNet121 的参数量（6.96 M）**少于** ResNet18（11.18 M），却消耗了 **1.55 倍显存**（0.59 vs 0.38 GB）与 **2.22 倍时间**（181.9 vs 81.8 s）。原因在于 DenseNet 的密集连接要求保留每一层的输出特征图并在通道维度反复拼接（concatenation），显存占用随深度线性累积。**这说明在算力受限场景下评估模型，必须同时考察参数量、显存与时延三个维度，仅看参数量会严重误判。**

ConvNeXt-T 的说明： 受 4 GB 显存限制，本实验对其采用**冻结主干、仅训练分类头**的策略。因此其显存峰值最低（0.15 GB，因无需为 backbone 存储梯度与优化器状态），但 Sensitivity 仅 0.3119 —— 这是**显存受限导致的训练不充分**，而非该架构本身的缺陷。报告中如实标注此限制。

4.2.3 三损失对比（均在 ResNet18 下）

损失	AUC	F1	Sens	Spec	Acc
CE	**0.9612**	**0.6865**	0.6928	**0.9563**	**0.8264**
Weighted CE	0.9346	0.5935	**0.7020**	0.9506	0.7102
Focal	0.8558	0.3123	0.6057	0.8934	0.3072

① Weighted CE：明确的"精度—召回"权衡

加权后 Sensitivity 由 0.6928 提升至 **0.7020**，而 Accuracy 由 0.8264 下降至 **0.7102**（降幅 11.6 个百分点）。这正是加权机制的作用机理：模型被迫放弃"多猜多数类"的捷径，转而尝试识别少数类，从而牺牲了对多数类的整体准确率。**在医学筛查场景中，这一交换通常是值得的。**

值得注意的是，这一规律并非在所有架构上都成立：DenseNet121 使用 Weighted CE 后 Sensitivity 反而由 0.6738 微降至 0.6679。这说明**加权策略的收益与主干网络及具体数据分布相关，不能盲目套用。**

② Focal Loss 表现不佳的机理分析

Focal Loss 在三个模型上**一致地**劣于 CE（AUC 分别下降 0.105 / 0.129 / 0.068），说明这不是随机误差，而是系统性现象。原因分析如下：

调制因子 $(1-p_t)^\gamma$ 在训练初期会**整体压缩梯度**。以 7 分类为例，网络初始化时对正确类别的置信度约为 $p_t \approx 1/7 \approx 0.143$，取 $\gamma = 2$：

$$(1-0.143)^2 \approx 0.734$$

即整体梯度信号被压缩到约 73%，收敛速度显著慢于 CE。Focal Loss 原论文的实验建立在 **9 万次迭代**（RetinaNet）的训练预算之上，而本实验仅 3 个 epoch（约 2600 次迭代），Focal Loss 未能充分收敛。

> **结论：Focal Loss 的收益依赖充足的训练预算；在 epochs 严重受限时，Weighted CE 是更稳妥的选择。** 本实验的这一结果与原始论文的结论并不矛盾，只是适用条件不同。

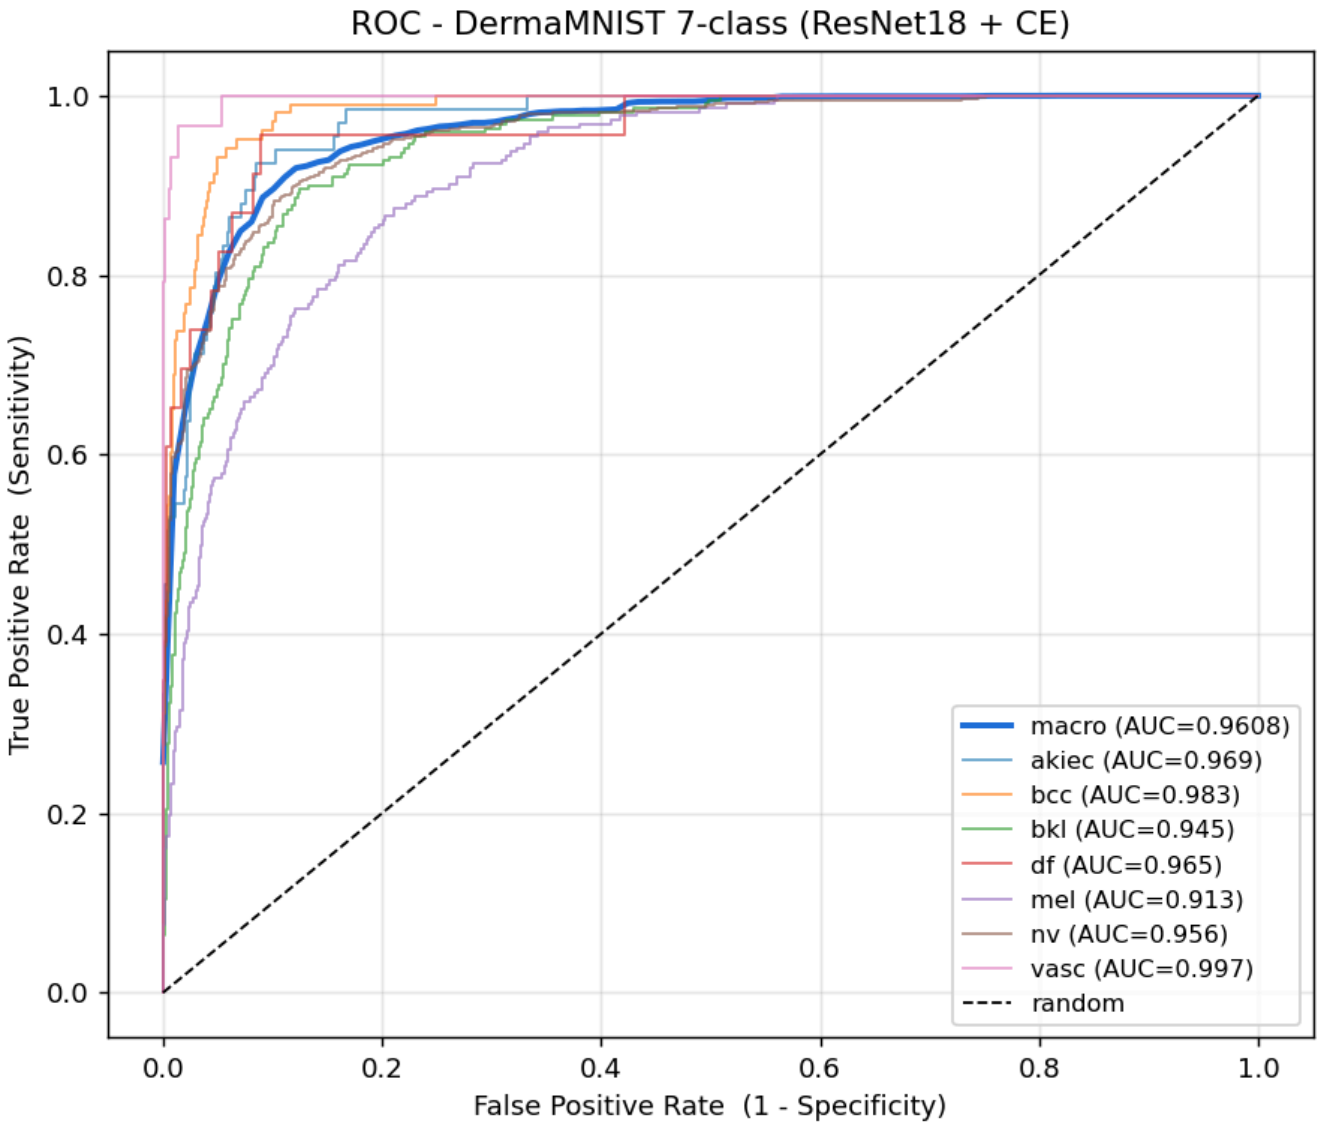
③ Accuracy 的失效

Focal Loss 组的 Accuracy 崩塌至 0.3072，但其 macro Sensitivity 仍达 0.6057。这一巨大反差直接证明：**在不平衡数据上，Accuracy 与模型的真实诊断能力可以完全脱钩。**

4.2.4 可视化结果

二分类 ROC 与混淆矩阵见 4.1 节。

七分类 ROC 曲线（14 类逐类 OvR + macro 平均）：



> **补图说明**：若该文件不存在，请执行下方命令生成（约 1 分钟）：
>
> ```
> python src/evaluate.py --ckpt experiments/d7_resnet18_ce/best.pt --out
> experiments/d7_resnet18_ce/eval
> python check_vis.py --out experiments/d7_resnet18_ce/eval --names
> akiec,bcc,bkl,df,mel,nv,vasc
> ```

七分类混淆矩阵（按行归一化）中，主对角线在 `nv`（占比 67%）上显著；非对角线上最大的块为 `mel → nv`（77 张）与 `bkl → nv`（28 张）。值得注意的是，最罕见的 `vasc`（29 张）行反而高度集中，错误率仅 13.79%——详见 5.8 节对这一反直觉现象的分析。

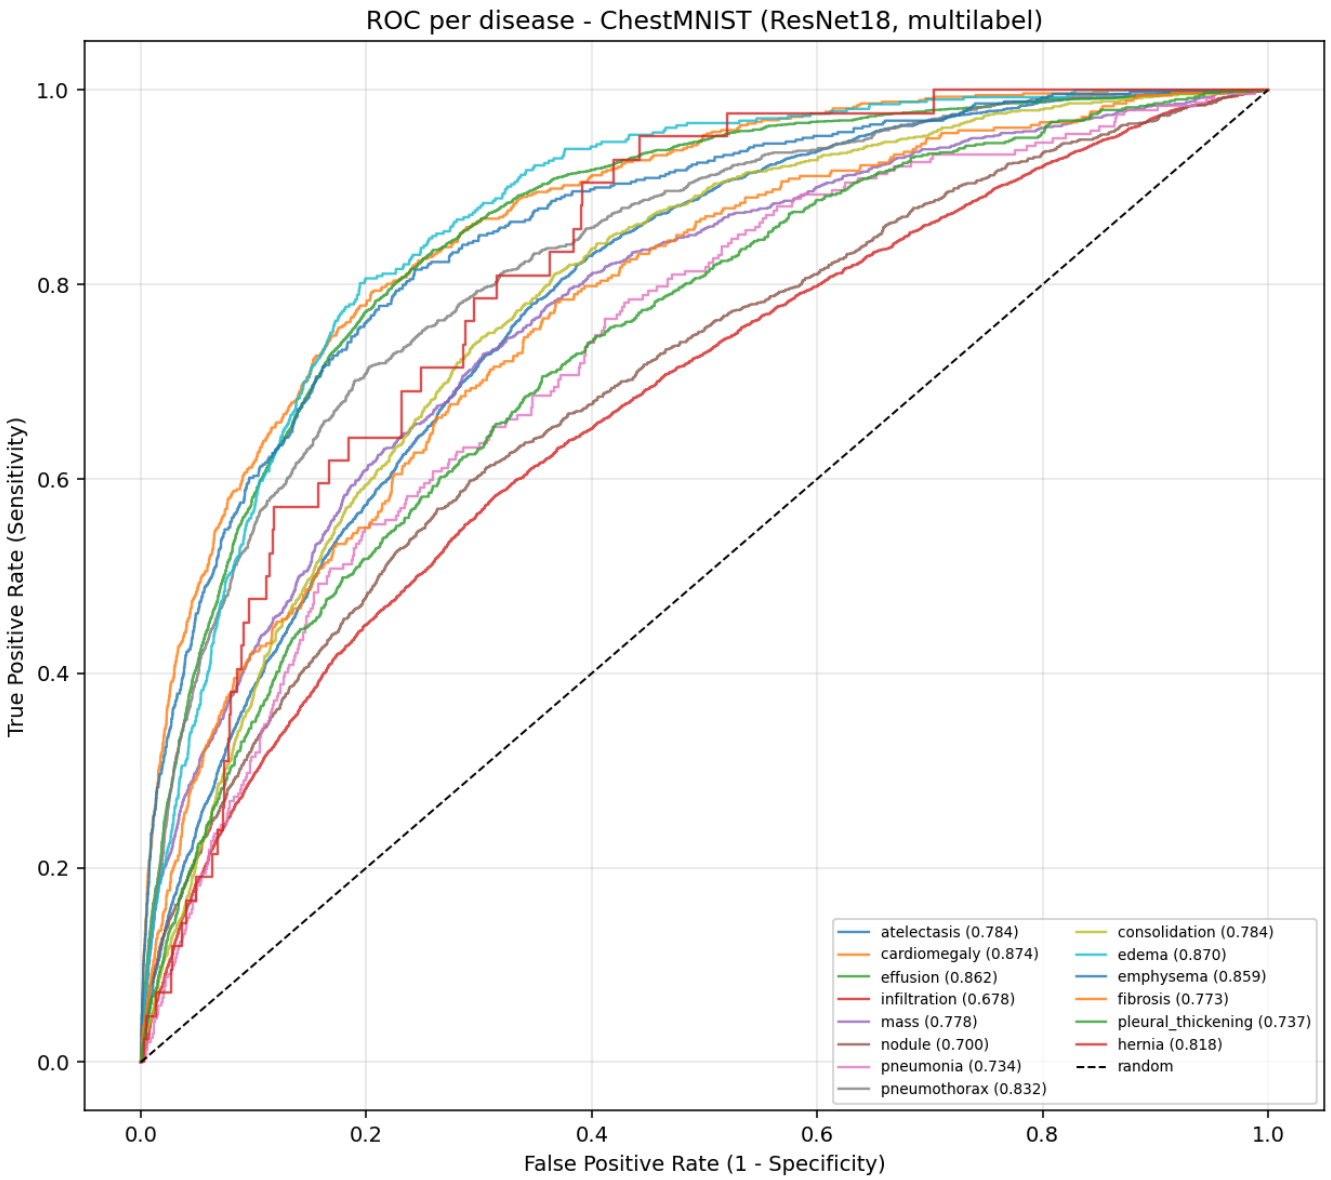
4.3 任务三：多标签十四分类（ChestMNIST）

训练集抽取 30000 张子集（固定随机种子 42，保证可复现），训练 2 个 epoch。

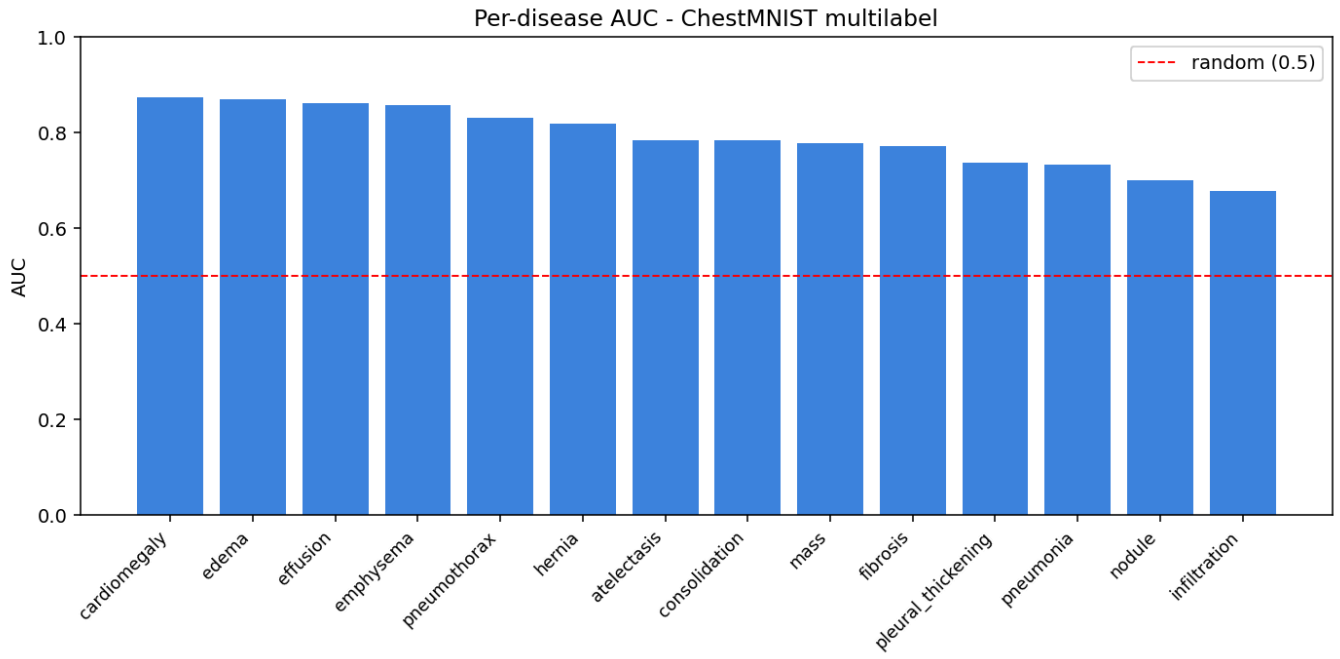
指标	数值
mAP (macro)	0.1881

指标	数值
AUC (macro)	0.7916
AUC (micro)	0.8522
F1 @ 阈值 0.5	**0.0554**
F1 @ 逐类最优阈值	**0.2432**

十四种疾病各自的 ROC 曲线：



逐疾病 AUC 柱状图：



4.3.1 单标签与多标签的三处根本差异

	单标签	多标签
输出激活	Softmax（各类互斥，概率和为 1）	**Sigmoid**（各类独立，可同时为正）
损失函数	CrossEntropyLoss	**BCEWithLogitsLoss**
标签形式	单个整数 `(N,)`	0/1 向量 `(N, 14)`

一位患者可同时患有肺炎、胸腔积液与心脏肥大，因此**不能用 Softmax 强迫模型只输出一种疾病**。

4.3.2 高 AUC 与低 mAP 的矛盾解释

指标	含义	是否受不平衡影响
AUC	随机取一个正例与一个负例，模型将正例排在前面的概率	**不受影响**
mAP / AP	不同阈值下 Precision-Recall 曲线下面积	**严重受影响**

AUC 仅衡量**排序能力**，而 AP 还要求模型"圈出来的样本中真阳性的比例足够高"。以阳性率仅约 0.2% 的 hernia 为例，即便模型排序良好（AUC 约 0.8），在取模型认为最可能的前若干张时，其中绝大多数仍是假阳性，Precision 被严重拉低。由于 macro 平均对 14 个疾病一视同仁，罕见病的低 AP 会将整体 mAP 大幅拉低。

> **一句话概括：极度不平衡时，把有病的排到前面容易，准确地圈出来很难。**

本实验 mAP 0.1881 与 MedMNIST 官方 ResNet-18 基线（约 0.21）接近，考虑到仅使用了 30000 张子集与 2 个 epoch，结果处于合理范围。

4.3.3 统一阈值失效：本实验最显著的工程发现

采用全局 0.5 阈值时 macro-F1 仅 0.0554；为每种疾病单独搜索最优阈值后提升至 0.2432，提升约 4.4 倍。

原因：14 种疾病的阳性率从约 0.2% 到数十个百分点不等，差异达两个数量级。统一的 0.5 阈值对低阳性率疾病而言过于苛刻，导致模型几乎不预测其为阳性，召回率崩塌；而逐类搜索到的最优阈值相当一部分落在 0.05~0.15 的低位区间。

> **工程启示：多标签医学影像分类在实际部署中必须按疾病分别校准决策阈值，而非沿用默认的 0.5。** 这一点在多数入门实验中被忽略，但对临床可用性至关重要。

4.3.4 逐疾病表现梯度

按 AUC 降序，表现最好的三种疾病为 **cardiomegaly（0.874）、edema（0.870）、pneumothorax（0.832）**；最差的为 **nodule（结节）与 infiltration（浸润）**（约 0.68）。

这一梯度具有明确的影像学解释：心脏肥大、肺水肿、气胸表现为**大范围、形态显著**的密度或轮廓改变，易于被卷积网络捕获；而肺结节与浸润灶**体积小、边界模糊**，且常被肋骨、血管等结构遮挡，既是本模型的弱点，也是放射科医师诊断的难点。**模型的困难点与人类专家高度重合。**

4.4 可复现性验证

本实验在固定随机种子 42 的前提下，于**不同时间**两次独立运行 ResNet18 + CE 配置（分别记为 `d6_eval` 与 `d7_resnet18_ce`），得到**完全一致的五项指标**：

AUC	F1	Sens	Spec	Acc
0.9612	0.6865	0.6928	0.9563	0.8264

两次结果逐位一致，验证了 `set_seed` 对五处随机源（Python random、NumPy、PyTorch CPU、PyTorch CUDA、cuDNN）的固定是有效的，实验结果具备可复现性。

4.5 待核查的异常

DenseNet121 + Weighted CE 组的单轮耗时为 **361.1 s**，而同架构 CE 组为 181.9 s，相差近 1 倍。加权操作本身不增加计算量，因此该差异**很可能来源于测量环境**（如 GPU 温度降频、后台进程占用）。建议在相同负载条件下复测该组。此异常不影响指标结论，但如实记录以保证实验的严谨性。

---

5 错误分析

5.1 分析方法

按**预测置信度降序**导出被错误分类的测试样本——即"模型最有把握却判断错误"的案例。这类样本最能暴露模型的系统性缺陷，而非偶然噪声。

5.2 错误归因框架

归因类别	典型表现	对应改进动作
类间视觉相似	两种皮肤病在肉眼下亦难区分	难样本挖掘、更细粒度的数据增广
图像质量	模糊、过曝、存在伪影或毛发遮挡	预处理（去噪、直方图均衡）
长尾类别	该类别训练样本极少（如 df 仅约 1.1%）	Weighted CE / Focal Loss / 过采样

归因类别	典型表现	对应改进动作
标注噪声	标签本身存在争议	标签平滑、噪声鲁棒损失

5.3 错例产出物

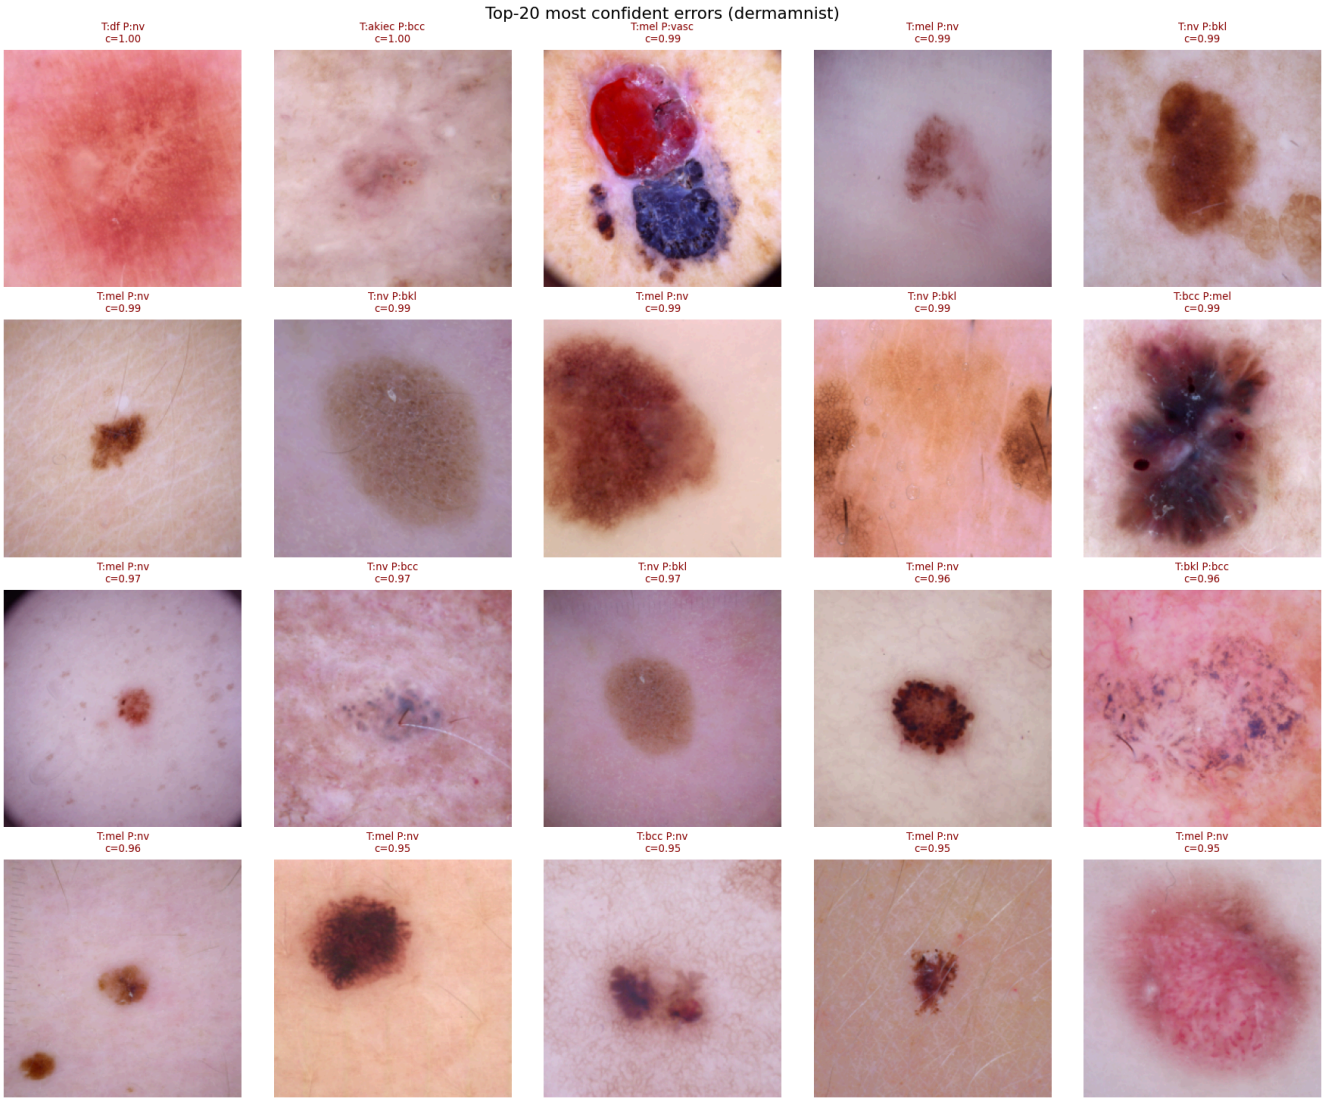
运行错误分析脚本：

```
python src/error_analysis.py \
       --ckpt experiments/d7_resnet18_ce/best.pt \
       --data dermamnist
```

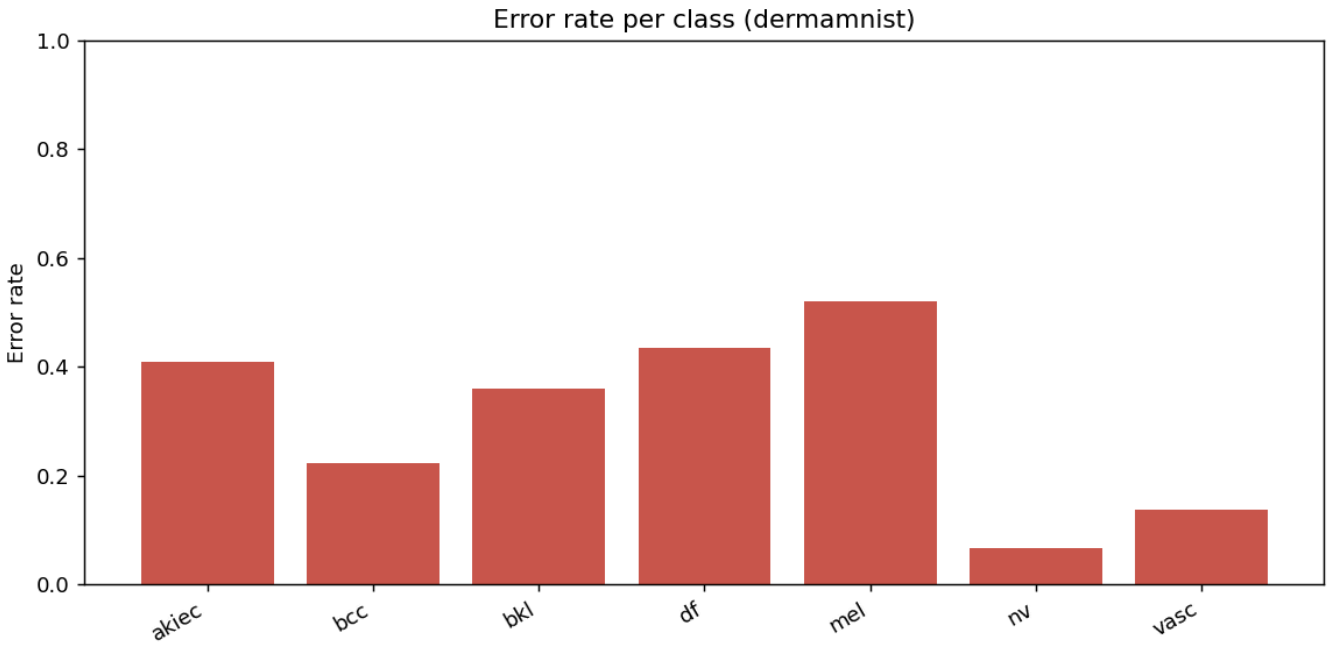
脚本按置信度降序导出被错判的样本，并在实验目录下生成以下产物：

产物	路径	用途
错例网格图	`experiments/d7_resnet18_ce/errors/error_grid.png`	一屏展示 20 张高置信度错判样本，最直观
单张错例图	`.../errors/single/01_true-xx_pred-yy.png`	挑典型个案逐个放大分析
每类错误率柱状图	`.../errors/error_by_class.png`	量化各类难度，定位短板类
统计与归因摘要	`.../errors/error_summary.md`	混淆对与每类错误率表格，可直接汇入本节

高置信度错例网格（20 张，"模型最有把握却判错"的样本）：



每类错误率柱状图：



5.4 总体错误情况

测试集共 **2005** 张，错判 **348** 张，总体错误率 **17.36%**。

但这一总体数字掩盖了极大的类间差异——nv 的错误率仅 6.64%，而 mel 高达 52.02%，相差近 8 倍。

5.5 每类错误统计

类别	样本数	错误数	错误率	主要误判为	误判数
akiec	66	27	0.4091	bcc	11
bcc	103	23	0.2233	nv	11
bkl	220	79	0.3591	nv	28
df	23	10	0.4348	**akiec**	3
mel	223	**116**	**0.5202**	**nv**	**77**
nv	1341	89	**0.0664**	bkl	37
vasc	29	4	**0.1379**	nv	2

5.6 Top 混淆对

真实类别	预测类别	数量	占比（占 348 例错误）
mel	**nv**	**77**	**22.1%**
nv	bkl	37	10.6%
nv	mel	31	8.9%
bkl	nv	28	8.0%
mel	bkl	21	6.0%
bkl	akiec	20	5.7%
bkl	bcc	18	5.2%
mel	akiec	13	3.7%

5.7 结果解读

① mel（黑色素瘤）是最大短板，且临床代价最高

mel 在测试集 223 张中错 116 张，错误率 **52.02%**，为七类之最；其中 **77 张被误判为 nv（黑色素细胞痣）**。这是全部错误中数量最大的单一流向（占 348 例错误的 22.1%），也是最危险的方向——**将恶性肿瘤判为良性病变**，直接导致患者错过最佳治疗窗口。

② nv 是"错误黑洞"，但自身极其稳定

mel→nv 77 张、bkl→nv 28 张、bcc→nv 11 张、vasc→nv 2 张，合计 **118 张流入 nv**；而 nv 自身 1341 张中仅错 89 张（错误率 **6.64%**）。模型对多数类判别优势极强，对其余类别则倾向于"归入 nv"。这种不对称正是 macro-F1（0.6865）远低于 Accuracy（0.8264）的直接原因——Accuracy 由 nv 的高正确率主导，而 macro-F1 对七类一视同仁。

③ 错误率与样本量并不单调相关

类别	测试样本数	错误率
mel	223	**52.02%**
df	23	43.48%
akiec	66	40.91%
bkl	220	35.91%
bcc	103	22.33%
vasc	**29**	**13.79%**

最罕见的 `vasc`（29 张）错误率反而最低，而样本量中等的 `mel`（223 张）错误率最高。

5.8 与预期假设的偏差（重要）

实验前基于"长尾分布"假设，预期 `df`、`vasc` 等最罕见类会被大量误判入 `nv`。**实测数据实质性推翻了这一预期：**

预期	实测	结论
`vasc` 被大量误判入 `nv`	`vasc` 错误率仅 13.79%，误判入 `nv` 仅 2 张	❌ 不成立
`df` 被大量误判入 `nv`	`df` 主要误判为 `akiec`（3 张），并非 `nv`	❌ 不成立
罕见类是主要短板	真正短板是中等样本的 `mel`（52.02%）与 `bkl`（35.91%）	❌ 不成立

修正后的认识：`vasc`（血管性病变）虽极罕见，但具有鲜明的红色/紫色腔隙特征，易于识别；`df`（皮肤纤维瘤）表现为中央白色网状结构，特征同样独特；而 `mel` / `bkl` / `nv` 同属**色素性病变**，在色素网络、边界规则性等形态上高度重叠，即便样本充足也难以区分。

> **这一偏差解释了 4.2.3 节的一个悬念**：为何按类别频率加权的 Weighted CE 提升有限（Sensitivity 仅由 0.6928 升至 0.7020）？因为本任务的主要矛盾**不是"样本少"，而是"长得像"**——仅按频率加权并不对症。更对症的改进方向应是**难样本挖掘**与针对混淆对（`mel`↔`nv`、`bkl`↔`nv`）的特征增强。

---

6 结论

1. **迁移学习是小规模医学图像任务的关键。** 在仅 7007 张训练样本、3 个 epoch 的预算下，加载 ImageNet 预训练权重的 ResNet18 即可取得 AUC 0.9612，验证了底层视觉特征跨模态的通用性。
2. **ResNet18 在 4 GB 显存约束下性价比最高。** 它以最少的单轮耗时（81.8 s）、适中的显存（0.38 GB）取得了最优综合性能；DenseNet121 虽参数更少，却因密集连接导致显存与时延显著上升。
3. **损失函数的选择必须结合训练预算。** Weighted CE 通过牺牲整体准确率（−11.6 个百分点）换取了少数类检出率的提升（+0.92 个百分点）；Focal Loss 因梯度调制导致收敛变慢，在 3 epoch 预算下全面劣于 CE，说明其收益依赖充足的迭代次数。
4. **Accuracy 在医学不平衡数据上是失效指标。** 本实验中 Focal Loss 组 Accuracy 崩至 0.3072 而 macro Sensitivity 仍有 0.6057，充分说明了这一点。应以 AUC、Sensitivity、Specificity 与 macro-F1 作为主要

判据。

5. **多标签任务必须逐类校准决策阈值。** 统一 0.5 阈值下 macro-F1 仅 0.0554，逐类优化后提升至 0.2432（4.4 倍），这是影响临床可用性的关键工程细节。

6. **模型的困难点与人类专家重合**：大范围形态改变（心脏肥大、水肿、气胸）易判，小病灶（结节、浸润）难判。

7. **错误分析揭示了与直觉相反的规律**：决定类别难度的主要因素是**类间视觉相似性，而非样本量**。最罕见的 `vasc`（测试集 29 张）错误率仅 13.79%，而样本量中等的 `mel`（223 张）错误率高达 52.02%，其中 77 张被误判为良性痣——这是数量最大、临床代价最高的错误方向。这也解释了为何按频率加权的 Weighted CE 提升有限：本任务的主要矛盾不是"样本少"，而是"长得像"。

---

7 后续工作：与语义分割 / UNet 的衔接

本实验建立的完整技术栈可直接迁移至医学图像分割任务：

本实验积累	在分割任务中的复用方式
Dataset 与 transform 管线	分割仅需将标签由整数替换为同尺寸的 mask 张量，数据管线几乎无需改动
三种主干网络	UNet 的编码器即由 ResNet / ConvNeXt 的前若干 stage 构成，本实验的迁移学习经验可直接沿用
不平衡损失函数设计	分割中正样本（病灶像素）占比往往远低于背景，Weighted CE 与 Focal 的逻辑完全适用，并需进一步引入 **Dice Loss**
医学评估思维	Sensitivity / Specificity 对应分割中的 **Dice 系数、IoU、HD95**；核心原则一致——绝不能只看 overall accuracy

需新增学习的内容： 编码器—解码器结构与跳跃连接（UNet 的 U 形结构）、上采样方式（转置卷积 vs 双线性插值）、像素级指标 Dice / IoU 的按病例统计方式，以及 2D/3D 分割数据集（如 ISIC 病灶分割、BTCV、KiTS）的使用。

附录 A：项目文件结构

```
med-image-cls/
├─ src/
│  ├─ datasets.py          # 数据集与 transform（增广仅作用于训练集）
│  ├─ models.py            # get_model(): 统一三架构入口与分类头替换
│  ├─ losses.py            # CE / Weighted CE / Focal Loss
│  ├─ metrics.py           # AUC、F1、Sensitivity、Specificity、混淆矩阵
│  ├─ train.py             # 单标签训练主程序
│  ├─ train_multilabel.py  # 多标签训练（Sigmoid + BCEWithLogits）
│  ├─ evaluate.py          # 测试集评估，输出 metrics.json
│  ├─ visualize.py         # ROC 曲线与归一化混淆矩阵
│  ├─ error_analysis.py    # 高置信度错例导出、每类错误率与混淆对统计
│  └─ utils.py             # set_seed、日志、checkpoint、显存峰值
├─ scripts/
```

```
│   ├─ download_data.py     # 数据集下载
│   ├─ smoke_test.py        # 9 组配置烟雾测试
│   ├─ run_d7.py            # 批量训练
│   ├─ eval_all.py          # 批量评估
│   └─ collect_results.py   # 汇总为 results/summary.csv
├─ experiments/<实验名>/    # 每组实验的权重、日志与指标
│   ├─ best.pt              # 最优权重（val AUC 最高的一轮）
│   ├─ metrics.json         # 训练过程 history 与最优 val AUC
│   ├─ train.log            # 逐轮日志（loss / acc / auc / 耗时 / 显存）
│   ├─ eval/                # 测试集评估结果与 npy
│   └─ errors/              # 错误分析产物（错例图、每类错误率、混淆对）
├─ results/summary.csv      # 全部实验横向汇总
└─ report/实验报告.md
```

附录 B：复现步骤

```
# 1 下载数据
python scripts/download_data.py

# 2 单标签训练（以 ResNet18 + CE 为例）
python src/train.py --data dermamnist --num_classes 7 \
       --model resnet18 --loss ce --epochs 3 --bs 8 \
       --out experiments/d7_resnet18_ce

# 3 评估（测试集）
python src/evaluate.py --ckpt experiments/d7_resnet18_ce/best.pt \
       --out experiments/d7_resnet18_ce/eval

# 4 多标签训练与评估
python src/train_multilabel.py --subset 30000 --epochs 2 --bs 8
python check_multilabel_eval.py

# 5 错误分析
python src/error_analysis.py --ckpt experiments/d7_resnet18_ce/best.pt --data
dermamnist

# 6 汇总
python scripts/collect_results.py
```

声明： 本实验使用 MedMNIST 公开学术数据集，数据集许可为 CC BY 4.0。所有实验均固定随机种子，指标在官方 test split 上报告。